

RAG

MentorCoffee

ETAPA 0 – Entender o Problema

- Os clientes tem relatado dificuldade (pain point) para escolher o grão ideal e efetuar a compra.
- Os clientes utilizam o site o que tem mais dificuldade são os que estão começando a conhecer cafés especiais.
- Os clientes relatam que não sabe preparar um café especial
- Essas dúvidas podem levar o cliente a desistir de uma compra, pois ele não consegue decidir.
- A empresa possui um **site**.

ETAPA 1 – Entender a Técnica RAG

- RAG (Retrieval Augmented Generation)
 - Recuperação
 - Geração
- Recuperação: O cliente abre o chatbot e faz uma pergunta:
 - Vocês vendem algum café descafeinado?
 - Precisamos recuperar essa informacao de uma base de conhecimento.
- Geração: Modelo de linguagem (LLMs) contextualiza a informação recuperada e responde à pessoa.
 - VANTAGEM: evita informações genéricas.

ETAPA 2 – Base de Conhecimento

- Estruturados: banco de dados, datawarehouse
- Não Estruturados (data lakes): .pdf, .csv , .xls, .xml, .json
- Vamos escolher um **.pdf**

Etapa 3 – Carregando os documentos

1. Instalando llama-index

1. ! pip install llama-index==0.12.17 gradio==5.16.0